

LAPORAN TEKNIS KOMPERHENSIF DATA SCIENTIST

PharmaSix

Sistem Prediksi dan Manajemen Stok obat untuk Mendukung Konsumsi Berkelanjutan



Oleh:

CC26-PSU085

Nama Anggota:

Arfira Andayani (CFCC525D6X0240) -Full-Stack Web Developer- Politeknik Negeri Banyuwangi

Fadhil Alva Dinanda Yansen (CACC589D6Y0462) - AI Engineer - Universitas Pertahanan Republik Indonesia

Bagas Asma Prawira (CACC589D6Y0472) - AI Engineer - Univeritas Pertahanan Republik Indonesia

Raissa Yasmin Salsabilla (CDCC284D6X2183) - Data Scientist - Universitas Negeri Surabaya

Sabrina Ganeshswara Putri (CDCC284D6X2738) - Data Scientist - Universitas Negeri Surabaya

Amelia Ayudyaning Tiko Putri (CFCC284D6X2837) - Full-Stack Web Developer - Universitas Negeri Surabaya

DAFTAR ISI

DAFTAR ISI	2
DAFTAR GAMBAR	4
DAFTAR TABEL	4
A. Executive Summary	5
B. Business Understanding	5
C. Data Understanding	6
D. Data Wrangling	7
1. Gathering Data	7
2. Assessing Data	8
2.1 Mengecek Struktur Dataset	8
2.2 Mengecek Nilai Unik pada Setiap Kolom	9
2.3 Mengecek Missing Values dan Duplicate Data	9
2.4 Mengecek Nilai Tidak Valid	10
2.5 Statistik Deskriptif	10
3. Cleaning Data	11
3.1 Menghapus Kolom yang Tidak Digunakan	11
3.2 Mengubah Format Tanggal dan Menghapus Duplikasi	11
3.3 Mengubah Angka Bulan Menjadi Nama Bulan	12
3.4 Merapikan Format Teks	12
E. Exploratory Data Analysis (EDA)	12
1. Explore Medicine, Year, dan Unit sold	13
2. Explore Medicine, Unit sold dan Year	14
3. Explore Demand dan Month	15
4. Explore Unit Sold dengan Semua Faktor Permintaan Obat	16
5. Explore Region dan Unit Sold	18
F. Visualization and Explanatory Analysis	19
1. Obat Apa yang Memiliki Volume Penjualan Tertinggi dan Terendah?	19
2. Bagaimana Tren Penjualan Obat dari Waktu ke Waktu?	20
3. Apakah Terdapat Pola Musiman dalam Permintaan Obat?	21
4. Bagaimana distribusi permintaan obat terhadap faktor yang memengaruhi permintaan obat?	22
5. Bagaimana Distribusi Permintaan Obat di Setiap Region?	23

G.	Feature Engineering	24
1.	Pembuatan Fitur Waktu.....	24
2.	Pembuatan Fitur Lag.....	25
3.	Pembuatan Rolling Mean.....	25
4.	Pembuatan Growth Rate	26
5.	Pembuatan Price Change	26
6.	Pembuatan Stock Coverage Days	26
7.	Pembuatan Near Expiry Indicator.....	27
8.	Pembersihan Data Setelah Feature Engineering	27
9.	Encoding Variabel Kategorikal	28

DAFTAR TABEL

Table 1. Fitur yang ada pada dataset obat	7
---	---

DAFTAR GAMBAR

Figure 1. Sampel Dataset Pharmasix	7
Figure 2. Proses Gathering Data	8
Figure 3. Dataset Info	8
Figure 4. Cek Konsistensi Dataset	9
Figure 5. Cek Duplikasi Dataset	9
Figure 6. Cek Value Unvalid Dataset.....	10
Figure 7. Memuat Info Statistik Deskriptif Dataset	10
Figure 8. Hapus Fitur Unrelevant	11
Figure 9. Konsistensi Dataset 1.....	11
Figure 10. Konsistensi Dataset 2.....	12
Figure 11. Konsistensi Dataset 3.....	12
Figure 12. Explore untuk Menjawab Question 1	13
Figure 13. Hasil Explore Question 1.....	13
Figure 14. Explore untuk Menjawab Question 2	14
Figure 15. Hasil Explore Question 2 (Sampel).....	14
Figure 16. Explore untuk Menjawab Question 3	15
Figure 17. Hasil Explore Question 3.....	16
Figure 18. Explore untuk Jawaban Question 4	16
Figure 19. Hasil Explore Question 4.....	17
Figure 20. Explore untuk Jawaban Question 5	18
Figure 21. Hasil untuk Question 5	18
Figure 23. Kontribusi Penjualan Obat (%) (2020-2025).....	19
Figure 24. Tren Persentase Penjualan Tiap Obat (2020–2025).....	20
Figure 25. Pola Musiman Penjualan Obat (2020-2025).....	21
Figure 26. Rata - Rata Penjualan Obat Setiap Negara	22
Figure 27. Distribusi Permintaan Obat di Setiap Region	23
Figure 28. Membuat Fitur Waktu pada FE.....	24
Figure 29. Membuat Fitur Lag pada FE.....	25
Figure 30. Membuat Rolling Mean 2 Periode Sebelumnya pada FE.....	25
Figure 31. Membuat Growth Rate pada FE	26
Figure 32. Membuat Price Change pada FE	26
Figure 33. Menghitung Stock Coverage Days	26
Figure 34. Membuat Indikator Expired pada FE	27
Figure 35. Membersihkan Data Setelah FE	27
Figure 36. Menampilkan Hasil FE.....	28
Figure 37. Proses Encoding pada FE	28
Figure 38. Hasil Encoding pada FE	29

A. Executive Summary

PharmaSix merupakan sistem berbasis teknologi yang dikembangkan untuk membantu fasilitas kesehatan dalam memprediksi kebutuhan stok obat dan mengelola persediaan secara lebih efisien. Proyek ini dibuat karena sering terjadi ketidaksesuaian antara jumlah stok dan permintaan obat yang dapat menyebabkan overstock, stockout, serta risiko obat kedaluwarsa.

PharmaSix memanfaatkan data historis penjualan obat untuk menganalisis tren penjualan dan menghasilkan prediksi kebutuhan obat di masa mendatang. Hasil prediksi tersebut kemudian dibandingkan dengan jumlah stok yang tersedia untuk mengetahui apakah persediaan masih aman atau perlu ditambah.

Dalam pengembangannya, PharmaSix menggunakan proses data science seperti data wrangling, EDA, visualisasi data, dan feature engineering. Hasil analisis menunjukkan bahwa penggunaan data historis dapat membantu pengambilan keputusan stok obat secara lebih akurat, efisien, dan mendukung pengelolaan *inventory* yang berkelanjutan.

B. Business Understanding

Untuk mendukung tujuan PharmaSix dalam memahami pola penjualan dan pengelolaan stok obat, dibuat beberapa pertanyaan bisnis sebagai dasar analisis data. Pertanyaan ini juga akan menjadi acuan dalam proses analisis data dan *handover* kepada tim AI Engineer dan Full Stack Development agar pengembangan sistem dapat dilakukan lebih terarah dan sesuai kebutuhan bisnis.

1. Obat apa yang mempunyai volume penjualan tertinggi dan terendah dari tahun 2020 hingga 2025?

Identifikasi obat dengan volume penjualan tertinggi penting untuk mengetahui produk dengan demand paling besar sehingga pengelolaan stok dapat diprioritaskan dan risiko stockout dapat diminimalkan. Sebaliknya, analisis terhadap obat dengan volume penjualan terendah membantu mendeteksi produk dengan perputaran lambat yang berisiko mengalami *overstock* atau kedaluwarsa, sehingga dapat menjadi bahan evaluasi *inventory* dan strategi distribusi.

2. Bagaimana tren penjualan obat dari 2020 hingga 2025?

Analisis tren penjualan dilakukan untuk melihat perubahan performa setiap obat dari waktu ke waktu, baik dalam bentuk peningkatan, penurunan, maupun pola penjualan yang stabil. Dengan memvisualisasikan penjualan per obat dari tahun 2020 hingga 2025, analisis ini dapat membantu mengidentifikasi obat yang mengalami pertumbuhan demand, penurunan minat pasar, atau perubahan performa yang signifikan. Informasi tersebut penting untuk mendukung evaluasi strategi *inventory*, pengadaan stok, serta pengambilan keputusan bisnis berdasarkan performa historis masing-masing obat.

3. Apakah terdapat pola musiman dalam penjualan obat dari 2020 hingga 2025?

Analisis ini dilakukan untuk melihat apakah penjualan obat memiliki pola berulang pada bulan-bulan tertentu. Dengan memahami kapan *demand* obat cenderung meningkat maupun menurun, fasilitas kesehatan dapat merencanakan pengadaan stok secara lebih optimal,

seperti meningkatkan persediaan pada periode *peak demand* dan mengurangi risiko *overstock* pada periode *low demand*. Selain itu, identifikasi *seasonality* juga membantu pengambilan keputusan *inventory* yang lebih efisien dan berbasis pola historis.

4. **Bagaimana distribusi permintaan obat terhadap faktor yang memengaruhi permintaan obat?**

Analisis ini bertujuan untuk mengevaluasi berbagai faktor yang berpotensi memengaruhi permintaan obat dan mengidentifikasi variabel dengan pengaruh paling dominan. Setelah dilakukan perbandingan antar faktor, hasil menunjukkan bahwa aspek geografis, khususnya **country**, memiliki pengaruh signifikan terhadap variasi *demand*. Oleh karena itu, analisis dilanjutkan dengan visualisasi rata-rata permintaan obat per *country* untuk memahami distribusi demand antar negara dan mendukung strategi alokasi stok yang lebih optimal.

5. **Bagaimana distribusi permintaan obat di setiap *region*?**

Permintaan obat dapat berbeda di setiap wilayah karena faktor demografis, kondisi kesehatan, maupun akses layanan kesehatan. Analisis ini membantu dalam memahami variasi permintaan antar region sehingga strategi distribusi dan alokasi stok dapat disesuaikan dengan kebutuhan masing-masing wilayah secara lebih tepat.

C. Data Understanding

Dataset yang digunakan pada proyek PharmaSix berisi data historis penjualan obat dari tahun 2020 hingga 2025. Dataset ini mencakup informasi terkait transaksi penjualan, karakteristik produk, *pricing*, *inventory*, serta beberapa fitur turunan yang digunakan untuk analisis lebih lanjut dan *predictive modeling*.

Dataset terdiri dari berbagai variabel yang relevan untuk memahami pola permintaan obat, menganalisis faktor yang memengaruhi penjualan, serta mendukung proses forecasting kebutuhan stok.

Table 1. Fitur yang ada pada dataset obat

Column	Description
date	Tanggal transaksi penjualan obat
year	Tahun transaksi
month	Bulan transaksi
day	Hari transaksi
region	Wilayah penjualan
country	Negara penjualan
category	Kategori obat
medicine	Nama obat
age_group	Kelompok usia konsumen
units_sold	Jumlah unit obat yang terjual
unit_price	Harga per unit obat
stock_level	Jumlah stok obat tersedia
expiry_days_remaining	Sisa hari sebelum obat kedaluwarsa
covid_flag	Indikator periode COVID-19 (0 = non-COVID, 1 = COVID)

date	year	month	day	region	country	category	medicine	age_group	units_sold	unit_price	stock_level	expiry_days_remaining	covid_flag
1/1/2020	2020	1	1	South Asia	Sri Lanka	Antibiotic	Amoxicillin	46-65	731	78.28	4347	123	1
1/1/2020	2020	1	1	North America	Canada	Antibiotic	Amoxicillin	0-12	709	8.52	4475	168	1
1/1/2020	2020	1	1	Oceania	Australia	Antibiotic	Amoxicillin	46-65	408	89.33	4670	603	1
1/1/2020	2020	1	1	East Asia	Japan	Antibiotic	Amoxicillin	65+	687	34.05	4432	186	1

Figure 1. Sampel Dataset Pharmasix

D. Data Wrangling

Pada tahap data wrangling, dilakukan proses pengumpulan, pemeriksaan, dan pembersihan data agar dataset siap digunakan untuk analisis lebih lanjut. Tahapan ini penting untuk memastikan kualitas data tetap konsisten sehingga hasil analisis dan modeling dapat lebih akurat dan terpercaya. Tahap ini dibagi menjadi 3 bagian, yakni:

1. Gathering Data

Pada tahap ini, dataset yang digunakan dalam proyek PharmaSix diperoleh dalam format CSV yang berisi data historis penjualan obat dari tahun 2020 hingga 2025. Dataset ini mencakup informasi sebagaimana yang tersaji pada Table 1. Data kemudian diimpor ke dalam environment Python menggunakan library **Pandas** untuk dilakukan proses analisis lebih lanjut.

```
1. Gathering Data

data_df = pd.read_csv('dataset.csv')
data_df.head()
```

	date	year	month	day	region	country	category	medicine	age_group	units_sold	unit_price	stock_level	expiry_days_remaining	covid_flag
0	2025-10-12	2025	10	12	Middle East	UAE	Chronic	Amlodipine	0-12	328	45.38	4774	466	0
1	2020-09-15	2020	9	15	South Asia	India	Chronic	Amlodipine	26-45	371	75.49	4584	181	1
2	2020-02-26	2020	2	26	Middle East	UAE	Vitamin	Vitamin C	0-12	948	22.51	3934	556	1
3	2025-11-09	2025	11	9	South Asia	Sri Lanka	Chronic	Amlodipine	0-12	275	63.29	4544	330	0
4	2022-04-04	2022	4	4	South America	Argentina	Chronic	Amlodipine	26-45	563	44.28	4284	590	0

Figure 2. Proses Gathering Data

2. Assessing Data

Assessing data adalah tahap pemeriksaan kualitas dan kondisi dataset sebelum dilakukan proses pembersihan maupun analisis lebih lanjut. Pada tahap ini dilakukan pengecekan terhadap struktur data, tipe data, missing values, duplicate data, serta kemungkinan adanya nilai yang tidak valid atau tidak konsisten. Tujuan dari proses assessing data adalah untuk memastikan dataset memiliki kualitas yang baik sehingga hasil analisis dapat lebih akurat dan terpercaya.

2.1 Mengecek Struktur Dataset

Pemeriksaan awal dilakukan untuk melihat jumlah data, tipe data, dan kelengkapan dataset.

```
data_df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 177990 entries, 0 to 177989
Data columns (total 14 columns):
 #   Column              Non-Null Count  Dtype
---  -
 0   date                177990 non-null object
 1   year                177990 non-null int64
 2   month               177990 non-null int64
 3   day                 177990 non-null int64
 4   region              177990 non-null object
 5   country             177990 non-null object
 6   category            177990 non-null object
 7   medicine            177990 non-null object
 8   age_group           177990 non-null object
 9   units_sold          177990 non-null int64
10   unit_price          177990 non-null float64
11   stock_level         177990 non-null int64
12   expiry_days_remaining 177990 non-null int64
13   covid_flag          177990 non-null int64
dtypes: float64(1), int64(7), object(6)
memory usage: 19.0+ MB
```

Figure 3. Dataset Info

Insight:

Dataset terdiri dari **177.990 baris** dan **14 kolom** dengan tipe data int64, float64, dan object. Seluruh kolom memiliki jumlah data non-null yang sama sehingga menunjukkan bahwa dataset tidak memiliki missing values dan siap digunakan untuk proses analisis lebih lanjut.

2.2 Mengecek Nilai Unik pada Setiap Kolom

Pemeriksaan dilakukan untuk memahami distribusi data dan memastikan konsistensi isi setiap kolom kategorikal.

```
a = data_df['year'].unique()
print (a)

b = data_df['month'].unique()
print(b)

c = data_df['day'].unique()
print(c)

d = data_df['region'].unique()
print(d)

e = data_df['country'].unique()
print(e)

f = data_df['medicine'].unique()
print(f)

g = data_df['age_group'].unique()
print (g)

h = data_df['covid_flag'].unique()
print (h)
```

Figure 4. Cek Konsistensi Dataset

Insight:

Hasil pengecekan menunjukkan bahwa dataset memiliki cakupan data yang cukup lengkap dengan periode transaksi dari tahun **2020–2025**, delapan region, serta beberapa negara dan jenis obat yang berbeda. Selain itu, nilai pada setiap kolom terlihat konsisten dan tidak ditemukan kategori yang tidak sesuai.

2.3 Mengecek Missing Values dan Duplicate Data

Pemeriksaan dilakukan untuk memastikan tidak terdapat data kosong maupun data duplikat yang dapat memengaruhi hasil analisis.

```
# Mencari duplikasi
print("Jumlah duplikasi:", data_df.duplicated().sum())

# Mencari missing values
data_df.isna().sum()
```

```
*** Jumlah duplikasi: 2630
0
date
year
month
day
region
country
category
medicine
age_group
units_sold
unit_price
stock_level
expiry_days_remaining
covid_flag
dtype: int64
```

Figure 5. Cek Duplikasi Dataset

Insight:

Hasil pengecekan menunjukkan bahwa dataset tidak memiliki missing values maupun duplicate data. Hal ini menunjukkan kualitas data yang cukup baik sehingga dapat langsung digunakan pada tahap cleaning dan analisis.

2.4 Mengecek Nilai Tidak Valid

Pemeriksaan dilakukan untuk memastikan tidak terdapat nilai yang tidak masuk akal pada beberapa kolom numerik penting.

```
#cek nilai yang tidak masuk akal
a = (
    (data_df['units_sold'] < 0) |
    (data_df['unit_price'] <= 0) |
    (data_df['stock_level'] < 0) |
    (data_df['expiry_days_remaining'] < 0)
).sum()

print("Jumlah nilai yang tidak masuk akal:", a)
```

Figure 6. Cek Value Unvalid Dataset

Insight:

Hasil pemeriksaan menunjukkan bahwa tidak terdapat nilai negatif maupun nilai tidak valid pada kolom numerik utama. Dengan demikian, dataset dinilai cukup konsisten dan logis untuk digunakan pada tahap analisis lebih lanjut.

2.5 Statistik Deskriptif

Pemeriksaan statistik dilakukan untuk memahami distribusi data numerik.

```
data_df.describe()
```

	year	month	day	units_sold	unit_price	stock_level	expiry_days_remaining	covid_flag
count	177990.000000	177990.000000	177990.000000	177990.000000	177990.000000	177990.000000	177990.000000	177990.000000
mean	2022.499702	6.521754	15.730457	447.913849	52.554729	4552.991780	374.038109	0.333519
std	1.708113	3.448703	8.801170	338.924528	27.421909	346.608511	199.759193	0.471471
min	2020.000000	1.000000	1.000000	31.000000	5.000000	0.000000	30.000000	0.000000
25%	2021.000000	4.000000	8.000000	284.000000	28.770000	4443.000000	200.000000	0.000000
50%	2023.000000	7.000000	16.000000	387.000000	52.600000	4598.000000	374.000000	0.000000
75%	2024.000000	10.000000	23.000000	529.000000	76.310000	4735.000000	547.000000	1.000000
max	2025.000000	12.000000	31.000000	8704.000000	100.000000	5124.000000	720.000000	1.000000

Figure 7. Memuat Info Statistik Deskriptif Dataset

Insight:

Statistik deskriptif membantu memahami karakteristik data seperti nilai minimum, maksimum, rata-rata, dan persebaran data pada setiap variabel numerik. Informasi ini berguna untuk mendeteksi potensi outlier serta memahami pola umum pada dataset sebelum dilakukan analisis lebih mendalam.

3. Cleaning Data

Setelah proses pengecekan pada tahap assessing data selesai dilakukan, tahap selanjutnya adalah cleaning data. Pada tahap ini dilakukan proses pembersihan dan perbaikan data agar data lebih rapi, konsisten, dan siap digunakan untuk analisis serta proses prediksi. Tahap ini kami bagi menjadi beberapa bagian, yakni:

3.1 Menghapus Kolom yang Tidak Digunakan

Kolom day dan covid_flag dihapus karena tidak digunakan dalam proses analisis.

```
# Menghapus Kolom Day dan Covid_flag
data_df = data_df.drop(columns=['day', 'covid_flag'], errors='ignore')
```

Figure 8. Hapus Fitur Unrelevant

Insight:

Kolom day dihapus karena analisis difokuskan pada level bulanan, sedangkan kolom covid_flag tidak digunakan dalam proses analisis sehingga tidak memberikan kontribusi langsung terhadap tujuan penelitian.

3.2 Mengubah Format Tanggal dan Menghapus Duplikasi

Tahap ini dilakukan untuk memastikan format data sudah sesuai dan tidak terdapat data berulang.

```
# Mengganti format date (object) menjadi date time
data_df['date'] = pd.to_datetime(data_df['date'])

# Menghapus duplikasi
data_df = data_df.drop_duplicates()

# Mengecek jumlah duplikasi setelah dilakukan penghapusan data duplikat
print("Jumlah duplikasi:", data_df.duplicated().sum())
```

Figure 9. Konsistensi Dataset 1

Insight:

Kolom date berhasil diubah ke format datetime sehingga dapat digunakan untuk analisis berbasis waktu seperti tren penjualan dan *seasonality*.

Selain itu, pengecekan ulang menunjukkan tidak terdapat data duplikat setelah proses cleaning dilakukan.

3.3 Mengubah Angka Bulan Menjadi Nama Bulan

Transformasi dilakukan agar visualisasi dan pembacaan data menjadi lebih mudah dipahami.

```
#menambahkan nama bulan
bulan_dict = {
    1: 'Januari',
    2: 'Februari',
    3: 'Maret',
    4: 'April',
    5: 'Mei',
    6: 'Juni',
    7: 'Juli',
    8: 'Agustus',
    9: 'September',
    10: 'Oktober',
    11: 'November',
    12: 'Desember'
}
```

Figure 11. Konsistensi Dataset 2

Insight:

Perubahan format bulan dari angka menjadi nama bulan membantu meningkatkan keterbacaan data, terutama pada tahap visualisasi data dan pembuatan dashboard.

3.4 Merapikan Format Teks

Tahap ini dilakukan untuk memastikan konsistensi penulisan pada kolom kategorikal.

```
#konsistensi kolom kategori (upper dan lower sama)
cols = ['region', 'country', 'category', 'medicine', 'age_group']
data_df[cols] = data_df[cols].apply(lambda x: x.str.strip().str.title())
```

Figure 13. Konsistensi Dataset 3

Insight:

Perapihan format teks berhasil membuat penulisan data menjadi lebih konsisten dengan menghapus spasi berlebih dan menyeragamkan format huruf. Hal ini membantu mengurangi potensi inkonsistensi kategori pada proses analisis dan visualisasi data.

E. Exploratory Data Analysis (EDA)

Tahap ini dilakukan untuk mengeksplorasi dataset farmasi sebelum masuk ke tahap pemodelan. Tujuan utama dari EDA adalah memahami pola penjualan obat, melihat tren

permintaan dari waktu ke waktu, mengidentifikasi obat dengan permintaan tinggi dan rendah, serta mengetahui faktor-faktor yang berpotensi memengaruhi jumlah obat terjual.

Pada proyek PharmaSix, EDA menjadi tahap penting karena hasil eksplorasi data digunakan sebagai dasar dalam membangun sistem prediksi dan manajemen stok obat. Dengan memahami pola permintaan obat, sistem dapat membantu mengurangi risiko *overstock*, *stockout*, dan obat kedaluwarsa.

1. Explore Medicine, Year, dan Unit sold

```
# Agregasi total penjualan per medicine (2020-2025)
df_group = data_df.groupby('medicine').agg({
    'units_sold': 'sum'
}).reset_index()

# Hitung rata-rata total penjualan semua medicine
mean_all = df_group['units_sold'].mean()

# Klasifikasi fast moving / slow moving
df_group['kategori'] = df_group['units_sold'].apply(
    lambda x: 'Fast Moving' if x > mean_all else 'Slow Moving'
)

# Urutkan berdasarkan total penjualan
df_sorted = df_group.sort_values('units_sold', ascending=False)

# Ambil top 5 dan bottom 5
top = df_sorted.head(5)[['medicine', 'units_sold', 'kategori']]
bottom = df_sorted.tail(5)[['medicine', 'units_sold', 'kategori']]

# Tampilkan hasil
print("Top 5 Obat Terlaris 2020-2025:")
print(top)

print("\nBottom 5 Obat Tidak Laris 2020-2025:")
print(bottom)
```

Figure 14. Explore untuk Menjawab Question 1

Pada tahap ini dilakukan analisis total penjualan setiap jenis obat selama periode 2020 sampai 2025. Data dikelompokkan berdasarkan kolom *medicine*, kemudian jumlah *units_sold* dihitung untuk setiap obat. Kemudian, dilakukan perhitungan rata-rata penjualan seluruh obat yang nanti akan digunakan sebagai batas untuk mengklasifikasikan obat ke dalam dua kategori, yaitu **Fast Moving** apabila total penjualannya berada di atas rata-rata seluruh obat dan **Slow Moving** apabila total penjualannya berada di bawah rata-rata.

```
... Top 5 Obat Terlaris 2020-2025:
      medicine  units_sold  kategori
2  Azithromycin    7896771  Fast Moving
8   Paracetamol    7892260  Fast Moving
7  Multivitamin    7869649  Fast Moving
5    Ibuprofen    7867488  Fast Moving
6    Metformin    7865048  Fast Moving

Bottom 5 Obat Tidak Laris 2020-2025:
      medicine  units_sold  kategori
9    Vitamin C    7858526  Fast Moving
4   Cough Syrup    7847488  Slow Moving
3   Cetirizine    7831986  Slow Moving
0  Amlodipine    7822352  Slow Moving
1  Amoxicillin    7783016  Slow Moving
```

Figure 15. Hasil Explore Question 1

Hasil analisis menunjukkan bahwa obat dengan kategori **Fast Moving** adalah **Azithromycin, Paracetamol, Multivitamin, Ibuprofen, dan Metformin**. Sehingga, jenis obat ini perlu mendapatkan perhatian lebih dalam pengelolaan stok agar tidak mengalami kekurangan persediaan. Sementara itu, obat dengan kategori **Slow Moving** adalah **Vitamin C, Cough Syrup, Cetirizine, Amlodipine, dan Amoxicillin**. Sehingga perlu dikontrol agar tidak terjadi kelebihan stok yang dapat meningkatkan risiko obat tidak terjual atau kedaluwarsa.

2. Explore Medicine, Unit sold dan Year

```
# Agregasi total penjualan per obat per tahun
trend_med = (
    data_df.groupby(['medicine', 'year'], as_index=False)['units_sold']
    .sum()
)

# Mengurutkan nama obat berdasarkan abjad dan mulai dari tahun 2020
trend_med = trend_med.sort_values(['medicine', 'year']).reset_index(drop=True)

# Hitung perubahan atau selisih tahun sebelumnya untuk setiap permintaan obat
trend_med['change'] = trend_med.groupby('medicine')['units_sold'].diff()

# Hitung persentase perubahan dibanding tahun sebelumnya untuk setiap obat
trend_med['growth_%'] = trend_med.groupby('medicine')['units_sold'].pct_change() * 100

# Buat label status tren untuk mengetahui distribusi obat dari tahun 2020-2025
def trend_status(change):
    if pd.isna(change):
        return 'Tahun awal'
    elif change > 0:
        return 'Naik'
    elif change < 0:
        return 'Turun'
    else:
        return 'Tetap'

# Menambahkan kolom trend_status untuk memberi gambaran terkait pola distribusi permintaan obat
trend_med['trend_status'] = trend_med['change'].apply(trend_status)

# Rapikan angka growth dengan mengambil 2 angka dibelakang koma agar lebih mudah untuk dibaca
trend_med['growth_%'] = trend_med['growth_%'].round(2)

# Tampilkan hasil lengkap
print("Tabel Tren Penjualan per Obat per Tahun:")
print(trend_med)
```

Figure 16. Explore untuk Menjawab Question 2

Pada tahap ini dilakukan analisis tren penjualan setiap obat berdasarkan tahun. Data dikelompokkan berdasarkan medicine dan year, kemudian jumlah units_sold dihitung untuk melihat total permintaan setiap obat pada masing-masing tahun.

Kemudian, pada tahap ini dilakukan penghitungan:

- Change: selisih jumlah penjualan obat dibandingkan dengan tahun sebelumnya
- Growth Percentage: persentase perubahan penjualan dari tahun sebelumnya.
- Trend Status: untuk melihat tren penjualan obat dengan label awal tahun (karena di awal tahun), Naik, Turun, dan Tetap.

	medicine	year	units_sold	change	growth_%	trend_status
0	Amlodipine	2020	1727508	NaN	NaN	Tahun awal
1	Amlodipine	2021	1765203	37695.0	2.18	Naik
2	Amlodipine	2022	1078198	-687005.0	-38.92	Turun
3	Amlodipine	2023	1086076	7878.0	0.73	Naik
4	Amlodipine	2024	1097967	11891.0	1.09	Naik
5	Amlodipine	2025	1067400	-30567.0	-2.78	Turun
6	Amoxicillin	2020	1722877	NaN	NaN	Tahun awal
7	Amoxicillin	2021	1703018	-19859.0	-1.15	Turun
8	Amoxicillin	2022	1083626	-619392.0	-36.37	Turun
9	Amoxicillin	2023	1091530	7904.0	0.73	Naik
10	Amoxicillin	2024	1089158	-2372.0	-0.22	Turun

Figure 17. Hasil Explore Question 2 (Sampel)

Dari hasil tabel, terlihat bahwa sebagian besar obat mengalami penurunan cukup besar pada tahun 2022 dibandingkan tahun sebelumnya. Misalnya, Amlodipine mengalami penurunan sebesar **-38.92%**, Amoxicillin sebesar **-36.37%**, Azithromycin sebesar **-37.35%**, dan Paracetamol sebesar **-38.65%**. Hal ini menunjukkan adanya perubahan pola permintaan yang signifikan pada tahun tersebut. Setelah tahun 2022, beberapa obat mulai menunjukkan kenaikan 15actor15, meskipun tidak selalu konsisten. Contohnya, Multivitamin mengalami kenaikan pada tahun 2023 dan 2025, sedangkan beberapa obat lain masih menunjukkan pola naik turun.

Analisis ini bertujuan untuk melihat perubahan permintaan obat dari tahun ke tahun sebagai dasar dalam prediksi stok. Hasil analisis menunjukkan bahwa permintaan obat mengalami perubahan yang tidak stabil, sehingga 15actor waktu perlu dipertimbangkan agar prediksi kebutuhan obat lebih akurat.

3. Explore Demand dan Month

```
# Agregasi demand per bulan (angka 1-12)
monthly_demand = data_df.groupby(data_df['date'].dt.month)['units_sold'].sum().reset_index()

# Rename kolom bulan menjadi month number agar lebih mudah kami untuk menganalisa
monthly_demand.columns = ['month_num', 'units_sold']

# Ubah kolom month menjadi nama bulan
monthly_demand['month'] = monthly_demand['month_num'].apply(
    lambda x: pd.to_datetime(str(x), format='%m').strftime('%B'))

# Hitung mean dari permintaan obat berdasarkan bulan
mean_demand = monthly_demand['units_sold'].mean()

"""Memberi keterangan naik / turun terhadap mean. Jika lebih tinggi dari mean maka
distribusi naik dan jika lebih rendah dari mean maka distribusi turun"""

monthly_demand['keterangan'] = monthly_demand['units_sold'].apply(
    lambda x: 'Naik' if x > mean_demand else 'Turun')

# Menambahkan kolom persentase untuk mempermudah pemahaman kami dalam menganalisa
monthly_demand['persentase_perubahan'] = monthly_demand['units_sold'].pct_change() * 100

# Membuat kolom persentase perubahan lebih rapi dan memunculkan 2 angka di belakang koma
monthly_demand['persentase_perubahan'] = monthly_demand['persentase_perubahan'].round(2).astype(str) + '%'

monthly_demand
```

Figure 18. Explore untuk Menjawab Question 3

Pada tahap ini dilakukan analisis permintaan obat berdasarkan bulan. Data dikelompokkan berdasarkan bulan dari kolom date, kemudian jumlah units_sold dihitung untuk mengetahui total penjualan obat pada setiap bulan.

Alasan analisis ini dilakukan untuk mengetahui apakah permintaan obat memiliki pola musiman atau perubahan tertentu pada bulan-bulan tertentu. Dalam pengelolaan stok obat, pola permintaan bulanan penting untuk dianalisis karena kebutuhan obat tidak selalu sama setiap bulan. Ada bulan tertentu yang dapat mengalami peningkatan atau penurunan penjualan, sehingga stok perlu disesuaikan. Berikut analisis yang kami lakukan:

1. Month: Kolom angka bulan kemudian diubah menjadi nama bulan agar hasil analisis lebih mudah dibaca
2. Keterangan: Jika total permintaan pada suatu bulan lebih tinggi dari rata-rata, maka bulan tersebut diberi keterangan **Naik**. Sebaliknya, jika berada di bawah rata-rata, maka diberi keterangan **Turun**
3. Persentase_perubahan: Melihat seberapa besar kenaikan atau penurunan permintaan obat setiap bulan.

	month_num	units_sold	month	keterangan	persentase_perubahan
0	1	7848747	January	Naik	nan%
1	2	7941982	February	Naik	1.19%
2	3	8982426	March	Naik	13.1%
3	4	8486167	April	Naik	-5.52%
4	5	7788156	May	Naik	-8.23%
5	6	6503034	June	Turun	-16.5%
6	7	5516091	July	Turun	-15.18%
7	8	4631415	August	Turun	-16.04%
8	9	4207651	September	Turun	-9.15%
9	10	4634775	October	Turun	10.15%
10	11	5332917	November	Turun	15.06%
11	12	6661223	December	Naik	24.91%

Figure 19. Hasil Explore Question 3

Hasil analisis menunjukkan bahwa permintaan obat memiliki pola musiman yang berubah pada periode tertentu. Penjualan cenderung meningkat dari Januari hingga mencapai puncaknya pada bulan Maret, kemudian mengalami penurunan bertahap hingga titik terendah pada bulan September. Setelah itu, permintaan kembali meningkat pada periode Oktober hingga Desember.

Pola ini menunjukkan bahwa faktor waktu berpengaruh terhadap tingkat permintaan obat. Oleh karena itu, analisis bulanan penting dilakukan agar sistem PharmaSix dapat memperkirakan kebutuhan stok dengan lebih akurat. Dengan mengetahui periode permintaan tinggi dan rendah, sistem dapat membantu mengurangi risiko kekurangan stok maupun kelebihan persediaan obat.

4. Explore Unit Sold dengan Semua Faktor Permintaan Obat

```
# 1. Copy data
df_analysis = data_df.copy()

# Binning variabel numerik
df_analysis['price_group'] = pd.cut(
    df_analysis['unit_price'],
    bins=5,
    labels=[
        'Sangat Murah', # pengelompokan harga
        'Murah',
        'Sedang',
        'Mahal',
        'Sangat Mahal'
    ]
)

df_analysis['expiry_group'] = pd.cut(
    df_analysis['expiry_days_remaining'],
    bins=[0, 30, 90, 180, 365, df_analysis['expiry_days_remaining'].max()],
    labels=[
        '<30 Hari', # pengelompokan sisa masa expired
        '30-90 Hari',
        '90-180 Hari',
        '180-365 Hari',
        '>365 Hari'
    ]
),
include_lowest=True
)

# Daftar faktor yang akan diuji untuk mengetahui apa yang paling berpengaruh terhadap permintaan obat
factors = [
    'region',
    'country',
    'category',
    'medicine',
    'age_group',
    'price_group',
    'expiry_group'
]

# Hitung variasi permintaan obat per faktor
hasil_pengaruh = []

for factor in factors:
    grouped = df_analysis.groupby(factor)['units_sold'].mean()

    hasil_pengaruh.append([
        factor, # menampilkan nama faktor
        round(grouped.max(), 2), # menampilkan mean tertinggi
        round(grouped.min(), 2), # menampilkan mean terendah
        round(grouped.max() - grouped.min(), 2), # menampilkan selisih min dan max dari mean
        round(grouped.std(), 2)
    ])

# Ranking faktor dari yang paling tinggi hingga rendah
pengaruh_df = pd.DataFrame(hasil_pengaruh)
pengaruh_df.sort_values('range', ascending=False)
pengaruh_df.reset_index(drop=True)

# Menampilkan hasil output
print("Ranking faktor yang Memengaruhi Permintaan Obat (2020-2025)\n")
display(pengaruh_df)
```

Figure 20. Explore untuk Jawaban Question 4

Pada tahap ini dilakukan analisis terhadap beberapa faktor yang berpotensi memengaruhi permintaan obat. Faktor yang dianalisis meliputi region, country, category, medicine, age_group, price_group, dan expiry_group.

Alasan analisis ini dilakukan adalah untuk mengetahui faktor mana yang memiliki pengaruh paling besar terhadap perubahan jumlah obat terjual. Dalam proyek PharmaSix, permintaan obat tidak hanya dipengaruhi oleh jenis obat, tetapi juga dapat dipengaruhi oleh lokasi penjualan, kategori obat, kelompok usia konsumen, harga obat, serta sisa masa kedaluwarsa. Oleh karena itu, analisis ini penting agar sistem dapat memahami faktor utama yang menyebabkan perbedaan permintaan obat. Berikut strategi yang kami lakukan sebelum menganalisis:

1. variabel numerik unit_price: dikelompokkan menjadi kategori **Sangat Murah, Murah, Sedang, Mahal, dan Sangat Mahal**
2. expiry_days_remaining: dikelompokkan menjadi **<30 Hari, 30–90 Hari, 90–180 Hari, 180–365 Hari, dan >365 Hari**.

Pengelompokan ini dilakukan agar data numerik lebih mudah dianalisis dan dibandingkan antar kelompok. Kemudian Analisis yang dilakukan adalah:

1. Range: Menunjukkan selisih antara rata-rata penjualan tertinggi dan terendah dalam suatu faktor
2. Standar deviation: menunjukkan tingkat sebaran data.

	factor	mean_max	mean_min	range	std_dev
0	country	452.53	442.86	9.67	2.72
1	medicine	450.32	443.83	6.49	1.94
2	region	449.33	444.07	5.26	1.89
3	price_group	450.95	446.81	4.14	1.76
4	expiry_group	449.70	446.37	3.33	1.22
5	category	449.35	447.07	2.29	1.02
6	age_group	449.12	446.92	2.20	0.95

Figure 21. Hasil Explore Question 4

Insight:

Berdasarkan hasil analisis, faktor yang paling berpengaruh terhadap penjualan obat adalah *country* karena memiliki variasi penjualan tertinggi dibandingkan faktor lainnya. Hal ini menunjukkan bahwa kebutuhan obat berbeda pada setiap negara sehingga pengelolaan stok perlu disesuaikan dengan karakteristik permintaan masing-masing negara. Hasil ini menunjukkan bahwa sistem PharmaSix perlu mempertimbangkan faktor *country* dalam proses prediksi dan rekomendasi stok agar pengelolaan persediaan obat menjadi lebih akurat dan efisien.

5. Explore Region dan Unit Sold

```
# Agregasi region dan unit sold untuk menampilkan jumlah dan rata - rata
region_demand = data_df.groupby('region')['units_sold'].agg(['sum','mean']).reset_index()

# Menambahkan tabel region demand column dengan 3 kolom yang akan ditampilkan
region_demand.columns = ['region', 'total_units_sold', 'mean_units_sold']

# Hitung persentase dari permintaan obat
total_all = region_demand['total_units_sold'].sum()
region_demand['persentase_kontribusi'] = (region_demand['total_units_sold'] / total_all) * 100

# Memberi peringkat dari region mana yang paling tinggi persentase kontribusinya
region_demand['rank'] = region_demand['total_units_sold'].rank(ascending=False, method='dense').astype(int)

# Menambahkan format persen pada kolom persentase kontribusi
region_demand['persentase_kontribusi'] = region_demand['persentase_kontribusi'].round(2).astype(str) + '%'

# Membuat hasil urut berdasarkan rank
region_demand = region_demand.sort_values('rank')

region_demand
```

Figure 22. Explore untuk Jawaban Question 5

Pada tahap ini dilakukan analisis terhadap `units_sold`, yaitu jumlah penjualan obat pada setiap *region* untuk mengetahui distribusi obat di setiap wilayah.

Analisis ini penting karena setiap *region* memiliki tingkat permintaan obat yang berbeda. Dengan mengetahui *region* yang memiliki kontribusi penjualan tinggi, sistem PharmaSix dapat membantu proses perencanaan stok agar distribusi obat menjadi lebih tepat dan risiko kekurangan maupun kelebihan stok dapat diminimalkan. Berikut yang kami lakukan:

1. `Mean_units_sold`: Kolom untuk melihat rata-rata penjualan obat pada suatu region
2. `Persentase_kontribusi`: Melihat seberapa besar persentase suatu permintaan obat di setiap region
3. `Rank`: Mengetahui urutan region yang memiliki *demand* tertinggi

	region	total_units_sold	mean_units_sold	persentase_kontribusi	rank
3	Middle East	9849229	449.326141	12.54%	1
5	Oceania	9847959	449.268203	12.54%	2
7	South Asia	9844922	449.129653	12.54%	3
6	South America	9838549	448.838914	12.53%	4
1	East Asia	9837720	448.801095	12.53%	5
4	North America	9799919	447.076597	12.48%	6
2	Europe	9782351	446.275137	12.46%	7
0	Africa	9733935	444.066378	12.39%	8

Figure 23. Hasil untuk Question 5

Insight:

Hasil analisis menunjukkan bahwa region seperti Middle East, Oceania, dan South Asia memiliki kontribusi penjualan tertinggi dibandingkan region lainnya. Hal ini menunjukkan bahwa wilayah tersebut memiliki tingkat permintaan obat yang lebih tinggi sehingga membutuhkan pengelolaan stok yang lebih optimal.

Permintaan obat pada setiap region menunjukkan perbedaan yang cukup signifikan. Oleh karena itu, faktor region perlu dipertimbangkan dalam sistem PharmaSix agar rekomendasi stok obat dapat disesuaikan dengan kebutuhan masing-masing wilayah secara lebih akurat dan efisien.

Berdasarkan hasil EDA yang telah dilakukan, dapat disimpulkan bahwa proses prediksi kebutuhan obat tidak dapat dilakukan hanya dengan melihat jumlah penjualan secara umum, tetapi perlu mempertimbangkan berbagai faktor yang memengaruhi permintaan obat. Hasil analisis menunjukkan bahwa jenis obat, pola waktu, musim penjualan, country, dan region memiliki pengaruh terhadap perubahan jumlah permintaan obat.

Temuan ini menjadi dasar penting sebagai pertimbangan dalam menentukan fitur yang relevan pada tahap machine learning, seperti penggunaan variabel waktu, lokasi penjualan, serta kategori obat dalam proses forecasting. Selain itu, hasil EDA juga membantu PharmaSix memahami pola permintaan secara lebih mendalam sehingga sistem dapat menghasilkan rekomendasi stok yang lebih adaptif, akurat, dan sesuai dengan kebutuhan setiap wilayah maupun periode tertentu.

Dengan demikian, tahapan EDA tidak hanya digunakan untuk memahami data, tetapi juga menjadi fondasi utama dalam proses pengembangan model prediksi dan pengambilan keputusan inventory agar risiko *stockout*, *overstock*, dan obat kedaluwarsa dapat diminimalkan secara lebih efektif.

F. Visualization and Explanatory Analysis

Pada tahap ini, analisis difokuskan untuk menjawab pertanyaan utama terkait penjualan obat. Dengan adanya visualisasi, hasil analisis dapat lebih mudah digunakan sebagai dasar pengambilan keputusan dalam sistem PharmaSix, terutama untuk mendukung prediksi kebutuhan stok obat dan mengurangi risiko *stockout*, *overstock*, serta obat kedaluwarsa. Berikut tahapan analisis kami:

1. Obat Apa yang Memiliki Volume Penjualan Tertinggi dan Terendah?

Pada bagian ini dilakukan visualisasi kontribusi penjualan setiap obat. Data diurutkan berdasarkan jumlah *units sold* dari yang tertinggi hingga terendah. Setelah itu, dihitung persentase kontribusi setiap obat terhadap total keseluruhan penjualan.




Figure 24. Kontribusi Penjualan Obat (%) (2020-2025)

Melalui visualisasi ini, perusahaan dapat mengetahui obat mana yang paling banyak diminati pasar dan obat mana yang memiliki permintaan paling rendah sehingga dapat menjadi dasar dalam strategi stok maupun distribusi.

Kesimpulan:

Berdasarkan hasil visualisasi distribusi penjualan obat periode 2020–2025, diketahui bahwa obat dengan volume penjualan tertinggi adalah **Azithromicyn**, sedangkan obat dengan penjualan terendah adalah **Amoxicilin**.

Meskipun terdapat perbedaan ranking penjualan antar obat, distribusi kontribusi penjualan terlihat relatif merata dengan persentase berkisar antara sekitar 9.97% hingga 10.06%. Hal ini menunjukkan bahwa tidak terdapat satu obat yang secara dominan menguasai pasar secara ekstrem. Dengan demikian, permintaan obat pada dataset cenderung tersebar secara cukup seimbang di berbagai jenis obat.

2. Bagaimana Tren Penjualan Obat dari Waktu ke Waktu?

Pada bagian ini dilakukan analisis tren penjualan obat. Data dikelompokkan berdasarkan medicine dan year, kemudian dihitung total units_sold pada setiap obat di masing-masing tahun. Setelah itu, terdapat dua langkah yang dilakukan, yaitu:

- Proses analisis dilakukan sama seperti pada tahap EDA nomor 2, namun ditambahkan kolom percentage agar hasil kontribusi penjualan dapat lebih mudah diinterpretasikan ketika divisualisasikan ke dalam grafik.
- Dibuat visualisasi tren penjualan masing-masing obat pada setiap tahun untuk melihat pola distribusi dan perubahan permintaan obat dari waktu ke waktu.

Analisis ini membantu memahami obat mana yang mengalami peningkatan maupun penurunan penjualan sehingga dapat digunakan sebagai dasar dalam proses forecasting dan pengelolaan stok.




Figure 25. Tren Persentase Penjualan Tiap Obat (2020–2025)

Kesimpulan:

Berdasarkan visualisasi, terlihat bahwa terjadi peningkatan signifikan pada penjualan obat dari tahun 2020 ke 2021, yang kemungkinan besar dipicu oleh meningkatnya permintaan akibat pandemi COVID-19.

periode setelahnya, yaitu 2022 hingga 2025, tren penjualan menunjukkan pola fluktuatif, namun tetap berada dalam rentang yang relatif stabil. Tidak terdapat lonjakan atau penurunan yang ekstrem seperti yang terjadi pada awal periode pandemi, sehingga dapat disimpulkan bahwa permintaan obat mulai kembali normal setelah tahun 2021.

3. Apakah Terdapat Pola Musiman dalam Permintaan Obat?

Pada bagian ini dilakukan analisis untuk mengetahui apakah permintaan obat memiliki pola musiman berdasarkan bulan. Data penjualan obat periode 2020–2025 dikelompokkan berdasarkan bulan, kemudian jumlah `units_sold` dihitung untuk mengetahui total permintaan obat pada setiap bulan.

Analisis ini bertujuan untuk melihat pola perubahan penjualan obat pada setiap bulan. Pola tersebut penting dalam pengelolaan *inventory* karena kebutuhan obat dapat meningkat atau menurun pada periode tertentu. Dengan memahami pola bulanan ini, PharmaSix dapat membantu menentukan jumlah stok yang lebih sesuai sehingga pengelolaan persediaan menjadi lebih efektif dan efisien.




Figure 26. Pola Musiman Penjualan Obat (2020-2025)

Kesimpulan:

Berdasarkan hasil analisis data penjualan obat periode 2020–2025 yang telah diagregasi per bulan, ditemukan adanya pola musiman (*seasonality*) dalam penjualan obat. Penjualan cenderung meningkat pada awal tahun, mencapai puncaknya pada bulan Maret, kemudian mengalami penurunan secara bertahap hingga mencapai titik terendah pada bulan September, dan kembali meningkat pada akhir tahun.

Selain itu, analisis terhadap rata-rata penjualan menunjukkan bahwa bulan-bulan pada awal dan akhir tahun sebagian besar berada di atas rata-rata (*high demand*), sedangkan bulan-bulan pertengahan tahun berada di bawah rata-rata (*low demand*). Pola ini menunjukkan adanya fluktuasi yang konsisten dan berulang dalam siklus tahunan, sehingga dapat disimpulkan bahwa permintaan obat tidak bersifat acak, melainkan dipengaruhi oleh faktor musiman.

4. Bagaimana distribusi permintaan obat terhadap faktor yang memengaruhi permintaan obat?

Pada bagian ini dilakukan analisis distribusi penjualan obat berdasarkan faktor *country*. Faktor ini dipilih karena pada analisis sebelumnya ditemukan bahwa **country memiliki nilai range tertinggi** dibandingkan faktor lainnya. Nilai range yang tinggi menunjukkan adanya perbedaan rata-rata permintaan obat antar kategori dalam faktor tersebut.

Analisis dilakukan dengan mengelompokkan data berdasarkan country, kemudian menghitung rata-rata *units_sold* pada setiap negara. Setelah itu, dihitung persentase kontribusi rata-rata penjualan ke tiap negara terhadap total rata-rata penjumlahan ke seluruh negara.

Alasan analisis ini untuk mengetahui apakah perbedaan negara benar-benar memberikan pengaruh terhadap jumlah obat yang terjual. Dalam konteks PharmaSix, informasi ini penting karena kebutuhan stok obat dapat berbeda pada setiap negara. Jika terdapat negara dengan permintaan yang lebih tinggi, maka perencanaan stok di negara tersebut perlu diprioritaskan agar tidak terjadi kekurangan stok. Sebaliknya, negara dengan permintaan lebih rendah perlu dikontrol agar tidak terjadi kelebihan stok.




Figure 27. Rata - Rata Penjualan Obat Setiap Negara

Kesimpulan:

Berdasarkan visualisasi distribusi permintaan obat per *country*, terlihat bahwa rata-rata *units_sold* antar negara relatif seragam tanpa adanya perbedaan yang mencolok. Temuan ini menunjukkan bahwa meskipun *country* merupakan faktor dengan pengaruh tertinggi dalam

analisis sebelumnya, pengaruh tersebut masih tergolong kecil secara praktis. Dengan demikian, penjualan obat pada dataset ini cenderung stabil dan merata di berbagai negara.

5. Bagaimana Distribusi Permintaan Obat di Setiap Region?

Pada tahap ini dilakukan analisis distribusi penjualan obat berdasarkan *region*. Data dikelompokkan berdasarkan region, kemudian dihitung total *units_sold* untuk masing-masing wilayah. Setelah itu, dihitung juga persentase kontribusi setiap region terhadap total keseluruhan permintaan obat.

Alasan analisis ini dilakukan untuk mengetahui apakah terdapat *region* tertentu yang memberikan kontribusi permintaan obat lebih besar dibandingkan *region* lainnya. Dalam konteks PharmaSix, informasi ini penting untuk membantu memahami pola distribusi permintaan berdasarkan wilayah, sehingga pengelolaan stok dapat mempertimbangkan kebutuhan tiap region secara lebih tepat.




Figure 28. Distribusi Permintaan Obat di Setiap Region

Kesimpulan:

Berdasarkan hasil analisis distribusi penjualan obat di berbagai region, ditemukan bahwa penjualan obat cenderung merata di seluruh wilayah. Hal ini terlihat dari nilai total penjualan, rata-rata penjualan, dan persentase kontribusi setiap region yang berada pada kisaran yang hampir sama, yaitu sekitar 12–13%. Dengan demikian, penjualan obat pada dataset ini cenderung stabil dan merata di berbagai wilayah.

G. Feature Engineering

Tahap *Feature Engineering* dilakukan setelah proses Exploratory Data Analysis dan Visualization Analysis. Tahap ini bertujuan untuk membentuk fitur-fitur baru dari data awal agar dataset menjadi lebih informatif dan dapat membantu model dalam memahami pola permintaan obat.

Pada proyek PharmaSix, *feature engineering* penting dilakukan karena pola penjualan obat tidak hanya dipengaruhi oleh data dasar seperti nama obat, negara, region, harga, dan stok, tetapi juga dipengaruhi oleh dinamika waktu, tren historis penjualan, perubahan harga, serta kondisi stok dan masa kedaluwarsa obat. Dengan menambahkan fitur baru, model diharapkan dapat mempelajari pola demand secara lebih akurat, terutama untuk kebutuhan prediksi stok obat. Dengan landasan itu, analisis yang kami lakukan, yakni:

1. Pembuatan Fitur Waktu

```
# Membuat fitur waktu
# Mengubah nama bulan Indonesia menjadi angka supaya bisa diproses model
month_mapping = {
    'Januari': 1, 'Februari': 2, 'Maret': 3, 'April': 4,
    'Mei': 5, 'Juni': 6, 'Juli': 7, 'Agustus': 8,
    'September': 9, 'Oktober': 10, 'November': 11, 'Desember': 12
}

data_df['month'] = data_df['month'].map(month_mapping)

# Menambahkan kuartal dan tahun dari kolom tanggal
data_df['quarter'] = data_df['date'].dt.quarter
data_df['year'] = data_df['date'].dt.year
```

Figure 29. Membuat Fitur Waktu pada FE

Pada tahap ini, kolom month yang awalnya berupa nama bulan dalam bahasa Indonesia diubah menjadi angka menggunakan mapping bulan. Contohnya, Januari diubah menjadi 1, Februari menjadi 2, Maret menjadi 3, dan seterusnya hingga Desember menjadi 12. Selain itu, dibuat juga fitur quarter dan year dari kolom date.

Fitur yang dihasilkan adalah:

month = bulan dalam bentuk angka
quarter = kuartal berdasarkan tanggal
year = tahun berdasarkan tanggal

Fitur waktu dibuat karena hasil analisis sebelumnya menunjukkan adanya pola musiman dalam permintaan obat. Permintaan obat dapat meningkat atau menurun pada bulan tertentu, sehingga informasi bulan, kuartal, dan tahun penting untuk membantu model mengenali pola demand berdasarkan waktu.

Dengan adanya fitur waktu, model dapat memahami bahwa permintaan obat tidak selalu sama setiap periode. Fitur ini membantu menangkap pola musiman, tren tahunan, dan perubahan demand berdasarkan waktu.

2. Pembuatan Fitur Lag

```
# Membuat fitur lag
# lag_1 = jumlah penjualan 1 periode sebelumnya
data_df['lag_1'] = (
    data_df.groupby('medicine')['units_sold'].shift(1)
)

# lag_2 = jumlah penjualan 2 periode sebelumnya
data_df['lag_2'] = (
    data_df.groupby('medicine')['units_sold'].shift(2)
)
```

Figure 30. Membuat Fitur Lag pada FE

Pada tahap ini dibuat fitur lag_1 dan lag_2. Fitur lag dibuat dengan cara mengelompokkan data berdasarkan medicine, kemudian mengambil nilai units_sold dari periode sebelumnya. Fitur lag dibuat karena penjualan obat pada periode saat ini bisa jadi dapat dipengaruhi oleh penjualan pada periode sebelumnya. Jika suatu obat memiliki penjualan tinggi pada periode sebelumnya, maka informasi tersebut dapat membantu model memperkirakan kemungkinan penjualan pada periode berikutnya.

Dengan adanya fitur lag_1 dan lag_2, model dapat mempelajari pola historis penjualan setiap obat. Hal ini penting untuk mendukung prediksi demand karena model tidak hanya melihat kondisi saat ini, tetapi juga mempertimbangkan riwayat penjualan sebelumnya.

3. Pembuatan *Rolling Mean*

```
# Membuat rolling mean
# Menghitung rata-rata penjualan 2 periode sebelumnya
data_df['rolling_mean_2'] = (
    data_df.groupby('medicine')['units_sold']
    .transform(lambda x: x.shift(1).rolling(2).mean()))
```

Figure 31. Membuat Rolling Mean 2 Periode Sebelumnya pada FE

Pada tahap ini dibuat fitur rolling_mean_2, yaitu rata-rata penjualan dari dua periode sebelumnya. Fitur ini dihitung berdasarkan masing-masing obat, sehingga rata-rata penjualan setiap obat dihitung secara terpisah. *Rolling mean* digunakan untuk menangkap pola rata-rata penjualan jangka pendek. Fitur ini membantu mengurangi pengaruh fluktuasi data yang terlalu tajam dan memberikan gambaran *demand* yang lebih stabil.

Dengan fitur rolling_mean_2, model dapat melihat pola rata-rata penjualan sebelumnya, bukan hanya penjualan pada satu periode terakhir. Hal ini membantu model memahami tren permintaan jangka pendek.

4. Pembuatan *Growth Rate*

```
# Membuat fitur tren penjualan
# Mengukur persentase kenaikan/penurunan penjualan dibanding periode sebelumnya
data_df['growth_rate'] = (
    data_df.groupby('medicine')['units_sold']
    .transform(lambda x: x.pct_change().shift(1)))
```

Figure 32. Membuat *Growth Rate* pada FE

Pada tahap ini dibuat fitur *growth_rate*, yaitu persentase kenaikan atau penurunan penjualan dibandingkan periode sebelumnya. Fitur ini dibuat untuk mengetahui arah perubahan *demand*. Model tidak hanya perlu mengetahui jumlah penjualan, tetapi juga perlu memahami apakah penjualan sedang meningkat atau menurun dibandingkan periode sebelumnya.

Fitur *growth_rate* membantu model mengenali tren pertumbuhan atau penurunan permintaan obat. Jika nilai *growth rate* positif, berarti penjualan meningkat. Jika nilainya negatif, berarti penjualan menurun.

5. Pembuatan *Price Change*

```
# Mengukur perubahan harga obat antar periode
data_df['price_change'] = (
    data_df.groupby('medicine')['unit_price'].pct_change()
)
```

Figure 33. Membuat *Price Change* pada FE

Pada tahap ini dibuat fitur *price_change*, yaitu persentase perubahan harga obat antarperiode. Perubahan harga dapat memengaruhi jumlah permintaan obat. Oleh karena itu, fitur *price_change* dibuat agar model dapat mempertimbangkan apakah perubahan harga memiliki hubungan dengan perubahan jumlah obat yang terjual. Dengan fitur *price_change*, model dapat menangkap dinamika harga sebagai salah satu faktor yang berpotensi memengaruhi *demand* obat.

6. Pembuatan *Stock Coverage Days*

```
# Membuat fitur stok
# Mengestimasi berapa lama stok bertahan berdasarkan rata-rata penjualan
data_df['stock_coverage_days'] = (
    data_df['stock_level'] / (data_df['rolling_mean_2'] + 1)
)
```

Figure 34. Menghitung *Stock Coverage Days*

Pada tahap ini dibuat fitur `stock_coverage_days`, yaitu estimasi berapa lama stok obat dapat bertahan berdasarkan jumlah stok saat ini dan rata-rata penjualan sebelumnya. Fitur ini dibuat untuk mengetahui kecukupan stok obat. Jika nilai `stock_coverage_days` rendah, maka stok berpotensi cepat habis. Sebaliknya, jika nilainya terlalu tinggi, maka terdapat potensi kelebihan stok.

Fitur ini sangat relevan dengan tujuan PharmaSix karena dapat membantu memperkirakan ketahanan stok. Dengan informasi ini, sistem dapat membantu mengurangi risiko *stockout* maupun *overstock*.

7. Pembuatan Near Expiry Indicator

```
# Menandai obat yang mendekati masa kedaluwarsa
# 1 = hampir expired (<90 hari), 0 = masih aman
data_df['near_expiry'] = (
    data_df['expiry_days_remaining'] < 90
).astype(int)
```

Figure 35. Membuat Indikator Expired pada FE

Pada tahap ini dibuat fitur `near_expiry`, yaitu indikator untuk menandai apakah obat mendekati masa kedaluwarsa. Masa kedaluwarsa merupakan faktor penting dalam pengelolaan stok obat. Obat yang mendekati *masa expired* perlu diperhatikan agar tidak terjadi pemborosan akibat obat tidak terjual sebelum kedaluwarsa.

Dengan fitur `near_expiry`, sistem dapat mengidentifikasi obat yang memiliki risiko kedaluwarsa lebih tinggi. Informasi ini dapat digunakan untuk mendukung prioritas distribusi atau pengambilan keputusan stok.

8. Pembersihan Data Setelah Feature Engineering

```
# Menghapus baris yang masih punya missing value pada fitur penting
data_df = data_df.dropna(subset=required_cols)
```

Figure 36. Membersihkan Data Setelah FE

Setelah fitur baru dibuat, dilakukan pembersihan data dengan mengganti nilai infinity menjadi NaN. Selanjutnya, data yang memiliki missing value pada kolom penting seperti `lag_1`, `lag_2`, dan `rolling_mean_2` dihapus. Hal ini dilakukan karena fitur lag dan rolling mean secara alami dapat menghasilkan missing value pada beberapa baris awal. Misalnya, data pertama suatu obat tidak memiliki data periode sebelumnya, sehingga nilai `lag_1` atau `lag_2` dapat kosong.

Missing value pada fitur penting dapat mengganggu proses analisis dan pemodelan. Oleh karena itu, baris yang masih memiliki missing value pada fitur utama perlu dihapus agar dataset akhir lebih bersih dan siap diproses.

Hasil Feature Engineering:

```
# Menampilkan hasil akhir feature engineering
print(data_df.head().to_string())
print(f"\nJumlah data setelah feature engineering: {len(data_df)}")
```

Figure 37. Menampilkan Hasil FE

- Setelah proses feature engineering, jumlah data akhir adalah
Jumlah data setelah feature engineering: 175340
- Hasil pengecekan missing value menunjukkan:
Total missing value dalam dataset: 0

Hasil ini menunjukkan bahwa dataset sudah bersih dari missing value dan siap disimpan dengan format .csv dan digunakan untuk tahap encoding serta analisis lanjutan.

9. Encoding Variabel Kategorikal

```
# ENCODING

# Menentukan kolom kategori yang akan diubah menjadi numerik
categorical_cols = ['region', 'country', 'category', 'medicine', 'age_group']

# Menyimpan encoder untuk setiap kolom (bisa dipakai lagi nanti)
label_encoders = {}

# Loop untuk setiap kolom kategori
for col in categorical_cols:
    le = LabelEncoder() # Membuat objek encoder
    data_df[col] = le.fit_transform(data_df[col]) # Mengubah kategori jadi angka
    label_encoders[col] = le # Menyimpan encoder

# Menampilkan hasil setelah encoding
display(data_df.head())
```

Figure 38. Proses Encoding pada FE

Setelah proses feature engineering selesai, dilakukan encoding pada variabel kategorikal. Encoding adalah proses mengubah data berbentuk teks menjadi bentuk numerik agar dapat diproses oleh model machine learning atau deep learning.

Kolom yang dilakukan encoding adalah:

- Region
- Country
- Category
- Medicine
- age_group

Proses encoding dilakukan menggunakan LabelEncoder, sehingga setiap kategori teks diubah menjadi angka. Model machine learning tidak dapat memproses data kategorikal dalam bentuk teks secara langsung. Oleh karena itu, variabel seperti region, negara, kategori obat, nama obat, dan kelompok usia perlu diubah ke bentuk numerik agar dapat digunakan pada tahap pemodelan.

Hasil Encoding:

	date	year	month	region	country	category	medicine	age_group	units_sold	unit_price	stock_level	expiry_days_remaining	quarter	lag_1	lag_2	rolling_mean_2	growth_rate	price_change	stock_coverage_days
3	2025-11-09	2025	11	7	15	2	0	0	275	63.29	4544	330	4	371.0	328.0	349.5	0.131098	-0.161611	12.964337
4	2022-04-04	2022	4	6	0	2	0	2	563	44.28	4284	590	2	275.0	371.0	323.0	-0.258760	-0.300363	13.222222
9	2022-11-04	2022	11	7	8	2	0	4	369	68.47	4524	174	4	563.0	275.0	419.0	1.047273	0.545296	10.771429
11	2025-12-26	2025	12	0	12	2	0	3	265	52.64	4562	424	4	369.0	563.0	466.0	-0.344583	-0.231196	9.768737
12	2024-11-21	2024	11	4	4	0	2	0	294	86.02	4663	523	4	130.0	243.0	196.5	-0.465021	0.131396	24.869333

Figure 39. Hasil Encoding pada FE

- Total missing value: 0
- kolom region, country, category, medicine berubah menjadi tipe numerik int64.

Proses encoding berhasil mengubah variabel kategorikal menjadi numerik tanpa menimbulkan missing value baru. Dengan demikian, dataset sudah lebih siap untuk digunakan oleh tim AI dalam proses pemodelan.

Catatan: pada kode ini, month tidak diencoding dengan LabelEncoder, tetapi diubah menjadi angka menggunakan mapping bulan. Jadi di laporan lebih tepat ditulis bahwa month dikonversi menjadi angka, sedangkan encoding dilakukan pada region, country, category, medicine, dan age_group.

Berdasarkan tahap feature engineering, dataset PharmaSix telah diperkaya dengan beberapa fitur baru, yaitu quarter, year, lag_1, lag_2, rolling_mean_2, growth_rate, price_change, stock_coverage_days, dan near_expiry. Fitur-fitur tersebut dibuat untuk membantu model menangkap pola *demand* secara lebih lengkap.

Setelah proses *Feature Engineering*, jumlah data akhir adalah **175340 data** dengan **20 kolom**. Hasil pengecekan menunjukkan bahwa tidak terdapat missing value pada dataset. Setelah itu, variabel kategorikal juga berhasil diubah menjadi numerik melalui proses encoding. Kemudian, data yang sudah di encoding akan di simpan dengan format .csv untuk di lanjutkan ke tim AI dan FS

Secara keseluruhan, tahap feature engineering ini penting karena menghasilkan fitur yang lebih relevan untuk kebutuhan prediksi demand. Dengan fitur yang lebih informatif, model diharapkan dapat menghasilkan prediksi kebutuhan stok obat yang lebih akurat dan mendukung sistem PharmaSix dalam mengurangi risiko *stockout*, *overstock*, dan obat kedaluwarsa.